

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC KINH TẾ THÀNH PHỐ HỒ CHÍ MINH



BÀI TIỂU LUẬN
MÔN HỌC: KHOA HỌC DỮ LIỆU
Đề tài: Dự đoán GPA cuối kỳ của học sinh phổ thông.

Giảng viên hướng dẫn: TS. Võ Văn Hải
Mã lớp học phần: 25D1INF50905915
Nhóm thực hiện: Nhóm 2
Sinh viên thực hiện:

Nguyễn Linh Anh – 31231020252
Cao Thị Trà Giang – 31231023133
Nguyễn Trần Thu Ngân – 31231024181

Thành phố Hồ Chí Minh, ngày 11 tháng 3 năm 2025

BẢNG PHÂN CÔNG

Họ tên	MSSV	Nhiệm vụ	Hoàn thành
Nguyễn Linh Anh	31231020252	Phần nội dung: Chương 2.I, II. Bước 3 đến bước 6; Chương 3.	100%
Cao Thị Trà Giang	31231023133	Phần mở đầu I; Phần nội dung: Chương 2. II. Bước 1, 2; Phần kết luận.	100%
Nguyễn Trần Thu Ngân	31231024181	Phần mở đầu II; Phần nội dung Chương 1.	100%

MỤC LỤC

PHẦN MỞ ĐẦU	4
GIỚI THIỆU ĐỀ TÀI NGHIÊN CỨU	4
I. Định hình vấn đề nghiên cứu.	4
1. Bối cảnh nghiên cứu.	4
2. Lí do chọn đề tài.	4
II. Các câu hỏi nghiên cứu xoay quanh chủ đề “Dự đoán GPA cuối kỳ của học sinh phổ thông”.	5
PHẦN NỘI DUNG	7
CHƯƠNG 1: CÁC NGHIÊN CỨU LIÊN QUAN VÀ NỀN TẢNG NGHIÊN CỨU ĐỀ TÀI “DỰ ĐOÁN GPA CUỐI KỲ CỦA HỌC SINH PHỔ THÔNG”.	7
I. Các nghiên cứu liên quan.	7
II. Nền tảng nghiên cứu đề tài.	8
CHƯƠNG 2: PHƯƠNG PHÁP NGHIÊN CỨU VÀ QUY TRÌNH THỰC NGHIỆM ĐỀ TÀI NGHIÊN CỨU “DỰ ĐOÁN GPA CUỐI KỲ CỦA HỌC SINH PHỔ THÔNG”. ..	9
I. Phương pháp nghiên cứu.	9
II. Quy trình thực nghiệm.	10
CHƯƠNG 3: KẾT QUẢ CỦA NGHIÊN CỨU VÀ THẢO LUẬN.	23
PHẦN KẾT LUẬN	25
KẾT LUẬN VÀ ĐỀ XUẤT NGHIÊN CỨU CHO TƯƠNG LAI.	25

PHẦN MỞ ĐẦU

GIỚI THIỆU ĐỀ TÀI NGHIÊN CỨU

I. Định hình vấn đề nghiên cứu.

1. Bối cảnh nghiên cứu.

Trong hệ thống giáo dục hiện nay, việc đánh giá kết quả học tập của học sinh đóng vai trò vô cùng quan trọng, đặc biệt đối với những em đang chuẩn bị xét tuyển vào đại học. Trong đó, GPA (Grade Point Average - Điểm trung bình học tập) là một chỉ số phổ biến, được xem là một thước đo phản ánh rõ ràng nhất về mức độ hoàn thành và chất lượng học tập, khả năng lĩnh hội kiến thức của học sinh qua mỗi học kỳ. Quan trọng, GPA còn là yếu tố then chốt trong nhiều phương thức tuyển sinh, đặc biệt là xét tuyển học bạ – một phương thức ngày càng được nhiều trường đại học ưa chuộng tại Việt Nam.

GPA luôn là một yếu tố mà bất kì học sinh nào cũng dành sự quan tâm đặc biệt. Bởi lẽ, việc sở hữu một GPA cao không chỉ thể hiện được những nỗ lực trong học tập của bản thân mà còn là cơ hội học bổng vào những trường đại học hàng đầu tại Việt Nam cũng như trên thế giới. Mới đây, nhiều trường đại học đã công bố phương án tuyển sinh năm 2025. Tính đến thời điểm hiện tại, có khoảng 70 trường sử dụng phương thức xét tuyển bằng học bạ. Chẳng hạn, Học viện Báo chí và Tuyên truyền dự kiến dành 20% chỉ tiêu để xét học bạ, tăng 5% so với năm 2024. Tại Đại học Quốc gia TP HCM, sẽ có 15% chỉ tiêu để xét tuyển thẳng, trong đó, đại học ưu tiên tuyển học sinh thuộc 149 trường THPT bằng điểm học bạ (danh sách các trường được cập nhật hằng năm) (Trang, 2025)[1]. Đối với những bạn có mong muốn đi du học tại các trường top đầu thế giới như Oxford, Stanford,... GPA lại đóng vai trò quan trọng hơn cả. Theo American Study, GPA trung bình của các ứng viên trúng tuyển vào các trường đại học top đầu Mỹ thường nằm trong khoảng từ 3.5 đến 4.0 trên thang điểm 4.0. GPA thấp có thể làm giảm cơ hội trúng tuyển, ngay cả khi ứng viên có các thành tích ngoại khóa ấn tượng (Thu, 2025)[2]. Những số liệu và ví dụ trên cho thấy GPA đóng vai trò quan trọng trong quá trình xét tuyển vào các trường đại học công lập, đặc biệt là các trường có tính cạnh tranh cao. GPA cao không chỉ phản ánh năng lực học tập mà còn tăng khả năng trúng tuyển của học sinh. Việc dự đoán được GPA cuối kì của bản thân giúp học sinh có thể thay đổi chiến thuật học tập để có thể đạt được GPA mong muốn, tăng cơ hội trúng tuyển vào các trường đại học mơ ước của mình.

2. Lí do chọn đề tài.

Trong thời đại 4.0 cùng với sự phát triển mạnh mẽ của trí tuệ nhân tạo (AI) và học máy (Machine Learning), những tiến bộ này là chìa khóa mở ra những cơ hội mới trong việc xây dựng các mô hình dự đoán điểm số với độ chính xác cao chỉ cần dựa trên dữ liệu đã có của học sinh, như điểm kiểm tra giữa kỳ, số giờ học tập, số buổi tham gia lớp học và một số yếu tố khác. Việc áp dụng các phương pháp này giúp các bạn học sinh phổ thông dự đoán được kết quả học tập của bản thân để điều chỉnh lại hành vi học tập phù hợp. Bên cạnh đó, đây còn là căn cứ giúp đội ngũ giáo viên trong việc nhận diện sớm các học sinh có nguy cơ học tập kém, từ đó đưa ra các biện pháp can thiệp kịp thời, nâng cao hiệu quả giảng dạy và hỗ trợ các em có thể trúng tuyển vào các trường đại học đúng với nguyện vọng. Đó cũng chính là lí do nhóm chúng em lựa chọn nghiên cứu đề tài “Dự đoán GPA của cuối kì học sinh phổ thông”.

Thông thường, điểm trung bình học kỳ của học sinh phổ thông (tức học sinh cấp 3) tại Việt Nam được tính trên thang điểm 10. Tuy nhiên, trong bài nghiên cứu này, chúng ta sẽ sử dụng thang điểm 4 để nhất quán với hệ thống giáo dục quốc tế. Nhiều hệ thống giáo dục trên thế giới, đặc biệt là Mỹ, Canada áp dụng thang điểm 4 trong đánh giá kết quả học tập cả cho học sinh phổ thông. Vì thế, việc sử dụng mô hình dự đoán theo thang điểm này không chỉ giúp dễ dàng so sánh với các nghiên cứu quốc tế mà còn mở rộng khả năng áp dụng trong nhiều bối cảnh khác nhau. Đồng thời, nó còn hỗ trợ các em học sinh cấp 3 đang chuẩn bị xét tuyển đại học có thể dễ dàng dự đoán kết quả và đánh giá năng lực của bản thân, từ đó có chiến thuật nâng cao học tập tốt. Ngoài ra, trong một số thuật toán học máy, việc làm việc với thang điểm nhỏ hơn (thang điểm 4) có thể giúp mô hình ổn định hơn và tránh ảnh hưởng của các giá trị quá lớn như thang điểm 10.

II. Các câu hỏi nghiên cứu xoay quanh chủ đề “Dự đoán GPA cuối kỳ của học sinh phổ thông”.

Mỗi nghiên cứu mới luôn luôn bắt đầu từ những thắc mắc xoay quanh, với nghiên cứu "Dự đoán GPA cuối kỳ của học sinh phổ thông" cũng không ngoại lệ. Việc tiếp cận những câu hỏi ấy không chỉ giúp chúng ta xác định đúng hướng đi mà còn định hướng được mục tiêu cũng như phương pháp và phạm vi thực hiện của nghiên cứu. Với vô vàn câu hỏi và thắc mắc được đặt ra, chúng ta đã tổng hợp thành 3 câu hỏi phổ biến nhất về chủ đề.

Đầu tiên, ***“Các yếu tố ảnh hưởng đến GPA cuối kỳ của học sinh là gì?”***

Đây là một câu hỏi vô cùng quan trọng trong quá trình thực hiện nghiên cứu. GPA chịu ảnh hưởng bởi nhiều yếu tố mang tính chủ quan và khách quan khác nhau như điểm số các môn trước đó, số giờ học tập trong tuần, số ngày nghỉ học, có tham gia hoạt động ngoại khóa hay

không, yếu tố cá nhân (sức khỏe, tâm lý), môi trường học tập, ... Có những yếu tố có ảnh hưởng rất lớn đến kết quả dự đoán, nhưng cũng có những yếu tố không có ảnh hưởng gì mà lại gây nhiễu cho mô hình dự đoán. Việc của chúng ta là xác định ra các yếu tố ảnh hưởng mạnh mẽ đến GPA của sinh viên, từ đó xây dựng mô hình dự đoán mạnh mẽ với độ tin cậy cao.

Tiếp đến, *“Thuật toán học máy nào là tối ưu và đem lại kết quả dự đoán có độ chính xác cao nhất?”*

Trong lĩnh vực học máy, có rất nhiều thuật toán có thể dự đoán GPA của học sinh như Hồi quy (Regression), Random Forest, Support Vector Machine (SVM), K-Nearest Neighbors (KNN), Mạng nơ-ron nhân tạo (Neural Network). Nhưng liệu phương pháp nào là tối ưu và thuật toán nào là phù hợp nhất để kết quả dự đoán cho ra được có độ chính xác cao nhất.

Cuối cùng, *“Ý nghĩa thực tiễn của nghiên cứu này là gì? Các bạn học sinh có thể cải thiện kết quả cuối kì của mình bằng cách nào dựa trên các dự đoán?”*

Đây là một vấn đề luôn được dành sự quan tâm đặc biệt từ các giáo viên, học sinh và cũng là đích đến của nghiên cứu. Câu trả lời của thắc mắc này không chỉ giúp các bạn học sinh điều chỉnh chiến lược học tập để đạt kết quả tốt hơn mà còn hỗ trợ các thầy cô trong việc can thiệp và hướng dẫn kịp thời, dựa trên các dự đoán từ mô hình nghiên cứu.

PHẦN NỘI DUNG

CHƯƠNG 1: CÁC NGHIÊN CỨU LIÊN QUAN VÀ NỀN TẢNG NGHIÊN CỨU ĐỀ TÀI “DỰ ĐOÁN GPA CUỐI KỲ CỦA HỌC SINH PHỔ THÔNG”.

I. Các nghiên cứu liên quan.

Để đạt được những bước tiến vượt bậc trong lĩnh vực khai thác dữ liệu giáo dục, rất nhiều các nghiên cứu đã được triển khai nhằm kết hợp các thuật toán học máy và khai thác dữ liệu với mục đích cải thiện độ chính xác trong quá trình dự đoán kết quả học tập của học sinh. Từ những dự đoán này, các bạn học sinh sẽ được cung cấp các thông tin hữu ích để tìm ra phương pháp học phù hợp và điều chỉnh chiến lược học tập của bản thân. Với lĩnh vực “Dự đoán GPA cuối kỳ của học sinh phổ thông”, chúng ta có một số nghiên cứu liên quan sau:

Nổi bật nhất không thể không kể đến nghiên cứu của **Romero & Ventura** vào năm **2013** về “**Data Mining in Education (EDM – Khai phá dữ liệu giáo dục)**”. Nghiên cứu này đã áp dụng các thuật toán học máy và phân tích thống kê để dự đoán điểm số cuối kỳ dựa trên các yếu tố như thời gian học, số giờ tham gia lớp học và kết quả các bài kiểm tra trước đó. Các thuật toán học máy được sử dụng trong nghiên cứu này là: Cây quyết định (Decision Trees); Hồi quy tuyến tính (Linear Regression); Mạng nơ-ron nhân tạo (Artificial Neural Networks - ANN),... (*Cristóbal Romero, 2013*)[3]. Chúng ta có thể sử dụng các thuật toán này để ứng dụng trực tiếp vào bài toán dự đoán GPA cuối kỳ của học sinh. Ví dụ, bằng cách sử dụng dữ liệu lịch sử về kết quả học tập, hệ thống có thể xác định những học sinh có nguy cơ điểm thấp và đưa ra cảnh báo sớm. Dựa trên nền tảng của Romero & Ventura, nhiều nghiên cứu hiện nay tiếp tục mở rộng bằng cách sử dụng các phương pháp tiên tiến hơn như học sâu (Deep Learning) hoặc học tăng cường (Reinforcement Learning) để dự đoán chính xác hơn.

Tiếp nối thành công đó, vào năm **2020**, **A. Ganaie** và nhóm nghiên cứu của ông đã thành công với nghiên cứu “**A Comparative Study of Machine Learning Algorithms for Predicting Student Performance (Nghiên cứu so sánh các thuật toán học máy để dự đoán hiệu suất của học sinh)**” bằng việc so sánh nhiều thuật toán như Random Forest, SVM và KNN trong bài toán dự đoán hiệu suất học tập. Nghiên cứu đã đi đến kết luận các thuật toán **Random Forest** và **SVM** đạt được độ chính xác cao nhất (*Ganaie, 2020*)[4]. Điều này nhấn mạnh tầm quan trọng của việc lựa chọn thuật toán phù hợp để đạt được kết quả dự đoán chính xác. Ứng dụng vào nghiên cứu dự đoán GPA của nhóm, khi áp dụng vào bài toán dự đoán, việc lựa chọn và so sánh các thuật toán học máy khác nhau, như đã được thực hiện trong nghiên cứu

của Ganaie, có thể giúp chúng ta xác định phương pháp tối ưu cho dữ liệu cụ thể của mình. Việc này không chỉ cải thiện độ chính xác của dự đoán mà còn cung cấp thông tin chi tiết về các yếu tố ảnh hưởng đến kết quả học tập của học sinh.

Ngoài ra, tại Việt Nam cũng có những nghiên cứu liên quan rất hữu ích trong việc “Dự đoán GPA cuối kỳ của học sinh phổ thông” của nhóm tốt hơn. Đó là nghiên cứu **"Dự báo kết quả học tập bằng kỹ thuật học sâu với mạng nơ-ron đa tầng"** của tác giả **Lưu Hoàng Sang** cùng với những người bạn **Nguyễn Thanh Hải, Trần Thanh Điện, Nguyễn Thái Nghe** vào năm 2020. Nghiên cứu này tập trung vào việc sử dụng **mạng nơ-ron đa tầng (Multilayer Perceptron - MLP)**, một dạng của mạng nơ-ron nhân tạo (Artificial Neural Network - ANN), để dự báo kết quả học tập của sinh viên. MLP có khả năng học và mô hình hóa các mối quan hệ phi tuyến tính phức tạp giữa các biến đầu vào và đầu ra, làm cho nó trở thành một công cụ mạnh mẽ trong việc dự đoán hiệu suất học tập (*Lưu Hoàng Sang, 2020*)[5]. Khi áp dụng vào bài toán dự đoán GPA, việc sử dụng mạng nơ-ron đa tầng có thể giúp mô hình hóa các mối quan hệ phức tạp và cải thiện độ chính xác dự đoán. Bằng cách tham khảo và áp dụng phương pháp từ nghiên cứu này, ta có thể xây dựng một mô hình dự đoán GPA hiệu quả, góp phần hỗ trợ học sinh trong việc cải thiện kết quả học tập và phát triển chiến lược học tập phù hợp.

II. Nền tảng nghiên cứu đề tài.

Trong nghiên cứu về chủ đề “Dự đoán GPA cuối kỳ của học sinh phổ thông”, có rất nhiều công cụ để hỗ trợ như Orange, Python, R Studio, RapidMiner,... Tuy nhiên, nhóm nghiên cứu quyết định sử dụng công cụ **Orange** vì đây là một nền tảng trực quan, dễ sử dụng và phù hợp cho việc xử lý dữ liệu cũng như triển khai các mô hình học máy mà không đòi hỏi quá nhiều kỹ năng lập trình. Hơn nữa, Orange tích hợp sẵn nhiều thuật toán phân tích dữ liệu, giúp nhóm có thể dễ dàng so sánh và đánh giá các mô hình dự đoán một cách hiệu quả.

Nghiên cứu áp dụng phương pháp học có giám sát (Supervised Learning), trong đó mô hình sẽ học từ dữ liệu đầu vào để dự đoán kết quả GPA. Các thuật toán khác nhau sử dụng trong nghiên cứu này là **Linear Regression, Gradient Boosting, Neural Network** sẽ được thử nghiệm và đánh giá độ chính xác dựa trên sai số trung bình và hệ số xác định, từ đó xác định mô hình tối ưu nhất.

Về dữ liệu nghiên cứu, nhóm lựa chọn dữ liệu thu thập từ kết quả khảo sát **hơn 1000** học sinh đến từ các trường Cấp 3 khác nhau, được chia sẻ trên Kaggle – một nền tảng trực tuyến uy tín chuyên về chia sẻ và phân tích dữ liệu. Khảo sát này tập trung thu thập những thông tin

về các yếu tố ảnh hưởng lên GPA của học sinh phổ thông, bao gồm: *Trung bình thời gian học mỗi tuần, số ngày nghỉ học, sự hỗ trợ từ phụ huynh, việc tham gia hoạt động ngoại khóa, việc chơi thể thao, việc học gia sư, tuổi tác, giới tính* của sinh viên. Những yếu tố này được lựa chọn nhằm phân tích mối quan hệ giữa hành vi học tập và thành tích học tập của học sinh (GPA), từ đó xây dựng mô hình dự đoán GPA một cách chính xác và khoa học.

CHƯƠNG 2: PHƯƠNG PHÁP NGHIÊN CỨU VÀ QUY TRÌNH THỰC NGHIỆM ĐỀ TÀI NGHIÊN CỨU “DỰ ĐOÁN GPA CUỐI KỲ CỦA HỌC SINH PHỔ THÔNG”.

I. Phương pháp nghiên cứu.

Để thực hiện nghiên cứu “Dự đoán GPA cuối kỳ của học sinh phổ thông”, nhóm lựa chọn sử dụng phương pháp **K-Fold Cross Validation** để đánh giá hiệu suất mô hình dự đoán. Phương pháp này giúp giảm thiểu sự phụ thuộc vào tập dữ liệu huấn luyện duy nhất và đảm bảo tính khách quan khi đánh giá mô hình.

Quy trình thực hiện mô hình “Dự đoán GPA cuối kỳ của học sinh phổ thông” bằng công cụ Orange gồm 6 bước chính:

1. Bước 1: Thu thập dữ liệu.

Thu thập dữ liệu từ nguồn khảo sát uy tín Kaggle để thu thập các thông tin liên quan và cần thiết cho mô hình dự đoán GPA của học sinh phổ thông.

2. Bước 2: Kiểm tra hệ số tương quan và trích xuất đặc trưng.

Xác định và chọn ra những đặc trưng quan trọng nhất có ảnh hưởng đến GPA để đưa vào mô hình dự đoán. Kiểm tra hệ số tuyến tính giữa các đặc trưng để đánh giá mức độ tương quan giữa các hệ số, đảm bảo không có hiện tượng đa cộng tuyến. Đồng thời, việc lựa chọn đặc trưng hợp lý giúp giảm nguy cơ overfitting, giúp mô hình hoạt động ổn định và hiệu quả hơn.

3. Bước 3: Tiền xử lý dữ liệu.

Tiền xử lý dữ liệu là quá trình xử lý dữ liệu thô (gốc) nhằm cải thiện chất lượng dữ liệu bằng cách xử lý các giá trị bị thiếu (missing data), chuẩn hóa các đặc trưng để đảm bảo tính

đồng nhất bằng widget Preprocess và loại bỏ nhiễu bằng cách xử lý các phần tử ngoại lai (outliers) bằng widget Outliers.

4. Bước 4: Dùng các mô hình học máy khác nhau để xử lý dữ liệu.

Sau khi tiền xử lý dữ liệu, nhóm thử nghiệm nhiều mô hình học máy khác nhau trong Orange, bao gồm hồi quy tuyến tính (Linear Regression), cây quyết định (Decision Tree), và mạng nơ-ron nhân tạo (Neural Networks). Các mô hình này được so sánh về hiệu suất để chọn ra mô hình tối ưu nhất.

5. Bước 5: Đánh giá các mô hình để lựa chọn thuật toán tối ưu nhất.

Nghiên cứu này sử dụng phương pháp K-Fold Cross Validation để đánh giá độ chính xác của mô hình. Cụ thể, dữ liệu được chia thành K phần bằng nhau, trong đó mô hình được huấn luyện trên K-1 phần và kiểm tra trên phần còn lại. Quá trình này lặp lại K lần để đảm bảo tính tổng quát của mô hình. Các chỉ số đánh giá như MAE (Mean Absolute Error), RMSE (Root Mean Square Error) và R^2 Score được sử dụng để đo lường hiệu suất của mô hình.

6. Bước 6: Dùng thuật toán tốt nhất để dự đoán GPA cuối kỳ của học sinh.

Sau khi xác định mô hình tối ưu, sử dụng mô hình đó để dự đoán GPA của học sinh dựa trên các đặc trưng đã chọn. Kết quả dự đoán được so sánh với giá trị thực tế để kiểm tra mức độ chính xác và tính ứng dụng của mô hình.

II. Quy trình thực nghiệm.

Sau khi đã xác định được 6 bước để thực hiện mô hình dự đoán GPA, chúng ta tiến hành triển khai từng bước theo quy trình đã đề ra.


- **Bước 1: Thu thập dữ liệu.**

Dữ liệu được sử dụng trong nghiên cứu này dựa trên tập dữ liệu *“Students Performance Dataset”* từ **Kaggle**, được đăng tải bởi tác giả Rabie El Kharoua với **1134 mẫu quan sát** cùng **10 biến** liên quan đến GPA của các học sinh Cấp 3 (Kharoua, 2024)[6].

STT	Tên biến	Ý nghĩa	Các giá trị của biến
1	StudentID	Mã học sinh	Biến định danh

2	Age	Tuổi	Biến liên tục (tuổi)
3	Gender	Giới tính	0: Nam 1: Nữ
4	StudyTimeWeekly	Trung bình thời gian học mỗi tuần	Biến liên tục (giờ/tuần)
5	Absences	Số ngày nghỉ học	Biến rời rạc (ngày)
6	Tutoring	Việc học gia sư	0: Có học gia sư 1: Không học gia sư
7	ParentalSupport	Sự hỗ trợ từ phụ huynh	0: Không có 1: Thấp 2: Trung bình 3: Cao 4: Rất cao
8	Extracurricular	Hoạt động ngoại khóa	0: Không có 1: Có
9	Sports	Thể thao	0: Không có 1: Có
10	GPA	Điểm trung bình	Biến liên tục

- Bước 2: Kiểm tra hệ số tương quan và trích xuất đặc trưng.**



Để xác định các yếu tố chính ảnh hưởng đến điểm trung bình (GPA) và lựa chọn các biến phù hợp với mô hình, nhóm sẽ sử dụng 3 phương pháp chính: **Correlations** (Hệ số tương quan); **Scatter Plot** (Biểu đồ phân tán); **Box Plot**.

1. Correlations (Hệ số tương quan).

	Feature 1	Feature 2	Correlation	uncorrected p	FDR
1	Absences	GPA	-0.781	1.66956e-233	8.34779e-233
2	GPA	ParentalSupport	0.16	6.3787e-08	1.59468e-07
3	GPA	StudyTimeWeekly	0.157	1.0121e-07	1.68683e-07
4	GPA	StudentID	-0.121	4.53182e-05	5.66478e-05
5	Age	GPA	-0.019	0.520531	0.520531

Dựa vào bảng kết quả của phân tích trên, nhóm em xác định được mức độ ảnh hưởng của các biến số đến GPA với mức ý nghĩa 5% (mức ý nghĩa phổ biến trong thống kê) như sau:


- **Absences** có hệ số tương quan mạnh nhất với GPA với giá trị âm 0.781, nghĩa là số ngày nghỉ học ảnh hưởng đáng kể đến GPA (số ngày nghỉ học càng cao thì GPA càng giảm). Ngoài ra, biến này có giá trị p rất nhỏ ($p = 1.66956e-233$) chứng tỏ mối quan hệ này có ý nghĩa thống kê mạnh.
- **ParentalSupport** và **StudyTimeWeekly** có tương quan dương với GPA với hệ số tương quan lần lượt là 0.16 và 0.157, tuy nhiên, mức độ tương quan này không quá mạnh. Mặt khác, với mức ý nghĩa 5%, hai biến này đều có $p < 0.05$ nên ta ưu tiên giữ lại để xem xét.
- **StudentID** và **Age** là 2 biến có hệ số tương quan thấp nhất trong bảng kết quả với giá trị lần lượt là -0.121 và -0.019. Thêm vào đó, giá trị p của biến Age lớn hơn 0.05 (0.520531), nghĩa là tuổi không có tác động đáng kể đến GPA. Trên thực tế, mã học sinh cũng không ảnh hưởng đến GPA nên ta quyết định loại bỏ hai biến này ra khỏi mô hình.

→ Dựa vào kết quả của phân tích tương quan (Correlations) trên, nhóm sẽ giữ lại các biến có hệ số tương quan cao, ảnh hưởng đến GPA để thực hiện dự đoán và loại bỏ các biến không có ý nghĩa thống kê như sau:

- **Giữ lại biến:** Absences, Parental Support, StudyTimeWeekly.
- **Bỏ qua các biến:** StudentID, Age.

2. Scatter Plot (Biểu đồ phân tán).

• Biểu đồ mối quan hệ giữa Absences (trục X) và GPA (trục Y).




- **Hệ số tương quan $r = -0.78$** , thể hiện mối quan hệ nghịch biến mạnh giữa số lần vắng mặt và GPA.
- Giá trị r tiến gần đến -1 cho thấy khi số lần vắng mặt tăng lên, GPA có xu hướng giảm mạnh. Nói cách khác, sự vắng mặt có ảnh hưởng tiêu cực đáng kể đến kết quả trung bình.

- **Đường hồi quy đen:** Có xu hướng dốc mạnh xuống, nghĩa là GPA giảm mạnh khi số lần vắng mặt tăng.

- Các điểm dữ liệu tập trung dày đặc ở phần trên bên trái → Những học sinh có số buổi nghỉ học ít thường có GPA cao hơn, và phân tán xuống dưới khi Absences tăng → GPA giảm dần khi số buổi nghỉ học tăng.

→ **Độ phân tán của các điểm dữ liệu cho thấy mối quan hệ tuyến tính khá rõ ràng.**

• Biểu đồ mối quan hệ giữa StudyTimeWeekly (trục X) và GPA (trục Y).




- **Hệ số tương quan $r = 0.16$** , thể hiện mối quan hệ đồng biến yếu giữa số giờ học trong tuần và GPA.

- Mặc dù r có giá trị dương nhưng mức độ ảnh hưởng rất nhỏ, cho thấy GPA có xu hướng tăng nhẹ khi thời gian học tăng nhưng không đáng kể.

- **Đường hồi quy đen:** Có độ dốc nhẹ, hướng lên.

- Tuy nhiên, vẫn ưu tiên **giữ** biến này để nghiên cứu vì thời gian học là một biến quan trọng để đánh giá thói quen học tập của học sinh. Dù ảnh hưởng của nó không mạnh, nhưng khi kết hợp với các yếu tố khác có thể đóng vai trò hỗ trợ trong việc nâng cao GPA. Ngoài ra, một số nghiên cứu giáo dục chỉ ra rằng *học nhiều giờ chưa chắc hiệu quả, nhưng học ít giờ thường sẽ ảnh hưởng tiêu cực đến kết quả học tập.*


- **Biểu đồ mối quan hệ giữa ParentalSupport (trục X) và GPA (trục Y).**



- **Hệ số tương quan $r = 0.16$.**
 - Tương tự với giá trị r của StudyTimeWeekly, giá trị r của ParentalSupport dương nhưng khá nhỏ cho thấy mối tương quan dương yếu giữa 2 biến, nghĩa là khi sự hỗ trợ từ phụ huynh tăng lên, GPA sẽ tăng lên tương ứng nhưng không mạnh.
 - **Đường hồi quy đen:** Độ dốc hướng lên rất yếu, cho thấy mức độ tác động của sự hỗ trợ từ bố mẹ đến điểm trung bình không đáng kể.
 - Các điểm dữ liệu không phân bố đồng đều và rõ ràng mà tập trung thành các cụm dọc chứng tỏ nó không hoàn toàn tuyến tính.
- ➔ **Quyết định loại bỏ ParentalSupport ra khỏi mô hình.**

3. Box Plot.

Sử dụng Box Plot để so sánh phân phối GPA giữa các nhóm của một biến định tính, từ đó xác định xem biến đó có ảnh hưởng đến GPA hay không.



Kết quả Box Plot thể hiện mối quan hệ giữa biến "Gender" và "GPA" trong Orange.

- **Phân tích phân bố dữ liệu**

Khoảng tứ phân vị (IQR – hộp màu xanh):

+ **Nhóm 0** (nhóm có giới tính nam): GPA nằm trong khoảng từ 2.296 (Q1) - 3.046 (Q3).

→ IQR = 0.75 với trung vị khoảng 2.637.

+ **Nhóm 1** (nhóm có giới tính nữ): GPA nằm trong khoảng từ 2.287 (Q1) - 3.055 (Q3).

→ IQR = 0.768 với trung vị khoảng 2.644.


→ Khoảng tứ phân vị của 2 nhóm rất tương đồng (khoảng 0.75) và chồng lẫn nhau gần như hoàn toàn chứng tỏ khoảng phân bố GPA giữa 2 nhóm là giống nhau và không có sự khác biệt đáng kể trong mức độ phân tán điểm số.

Kiểm định t-test, vẫn lựa chọn mức ý nghĩa 5%:

- Giá trị $t = 0.014 < t\text{-critical} = 1.96$
- Giá trị $p = 0.989 > \alpha = 0.05$

→ Không đủ căn cứ để bác bỏ giả thuyết không nên biến này không có ý nghĩa thống kê và có thể coi là không ảnh hưởng đáng kể đến GPA.

→ **Biến Gender không phải yếu tố phù hợp để đưa và dự đoán nên có thể loại bỏ biến này để giảm nhiễu và đơn giản hóa mô hình.**



Kết quả Box Plot thể hiện mối quan hệ giữa biến "Tutoring" và "GPA" trong Orange.

- **Phân tích phân bố dữ liệu**

Khoảng tứ phân vị (IQR – hộp màu xanh):

+ **Nhóm 0** (nhóm không học gia sư): GPA nằm trong khoảng 2.276 (Q1) - 2.968 (Q3).

→ IQR = 0.692 với trung vị khoảng 2.68.

+ **Nhóm 1** (nhóm có học gia sư): GPA nằm trong khoảng 2.333 (Q1) - 3.208 (Q3).

→ IQR = 0.875 với trung vị khoảng 2.799.


→ Nhóm 1 có khoảng IQR rộng hơn, cho thấy dữ liệu phân tán nhiều hơn so với nhóm 0. Dù có sự chồng lấn trong khoảng tứ phân vị nhưng GPA của nhóm 1 vẫn có xu hướng cao hơn do trung vị (2.799) và trung bình (2.78) của nhóm có học gia sư cao hơn nhóm không học gia sư.

Kiểm định t-test, vẫn lựa chọn mức ý nghĩa 5%:

- Giá trị $t = 4.422 > t\text{-critical} = 1.96$
- Giá trị $p = 0.000 < \alpha = 0,05$

→ Có thể bác bỏ giả thuyết không, tức là sự khác biệt giữa 2 nhóm có ý nghĩa thống kê. Nói cách khác, việc có học gia sư hay không sẽ ảnh hưởng đáng kể đến điểm trung bình.

→ **Biến Tutoring có ảnh hưởng đến GPA và nên được đưa vào mô hình dự báo.**



Kết quả Box Plot thể hiện mối quan hệ giữa biến "Extracurricular" và "GPA" trong Orange.

- **Phân tích phân bố dữ liệu**

Khoảng tứ phân vị (IQR - hộp màu xanh):

+ **Nhóm 0** (không tham gia hoạt động ngoại khóa): GPA chủ yếu nằm trong khoảng 2.264 (Q1) đến 2.996 (Q3) → IQR = 0.732 với trung vị khoảng 2.594.

+ **Nhóm 1** (có tham gia hoạt động ngoại khóa): GPA nằm trong khoảng từ 2.336 (Q1) - 3.114 (Q3) → IQR = 0.808 với trung vị xấp xỉ 2.711.


→ Nhóm 1 có IQR rộng hơn (0.808) cho thấy GPA trong nhóm này có mức độ phân tán cao hơn. Nói cách khác, sinh viên có tham gia hoạt động ngoại khóa có kết quả trung bình đa dạng hơn nhóm sinh viên không tham gia. Tuy nhiên, dù có sự khác biệt nhưng IQR vẫn chòng lún cho thấy một số sinh viên không tham gia hoạt động ngoại khóa vẫn có GPA cao và ngược lại, điều này chứng tỏ hoạt động ngoại khóa không phải là yếu tố duy nhất quyết định điểm trung bình.

Kiểm định t-test, vẫn lựa chọn mức ý nghĩa 5%:

- Giá trị $t = 4.210 > t\text{-critical} = 1.96$
- Giá trị $p = 0.000 < \alpha = 0.05$

→ Có thể bác bỏ giả thuyết không (H_0 : GPA của 2 nhóm là như nhau), nghĩa là việc tham gia hoạt động ngoại khóa có tác động đến GPA.

→ **Nên đưa biến Extracurricular vào mô hình để có thể cải thiện độ chính xác trong việc dự đoán.**



Kết quả Box Plot thể hiện mối quan hệ giữa biến "Sports" và "GPA" trong Orange.

• Phân tích phân bố dữ liệu

Khoảng tứ phân vị (IQR - hộp màu xanh):

+ **Nhóm 0** (không chơi thể thao): Điểm GPA nằm trong khoảng 2.27 (Q1) - 3.01 (Q3).

→ $IQR = 0.74$ với trung vị xấp xỉ 2.64.

+ **Nhóm 1** (có chơi thể thao): Điểm GPA nằm trong khoảng 2.32 (Q1) - 3.13 (Q3).

→ $IQR = 0.81$ với trung vị khoảng 2.63.

→ Khoảng tứ phân vị của nhóm 1 rộng hơn nhóm 0, cho thấy sự phân tán điểm trung bình của nhóm 1 cao hơn. Hai khoảng IQR có sự chồng lấn đáng kể, tức là có một số sinh viên không tham gia thể thao nhưng vẫn có GPA tương đương với sinh viên tham gia thể thao và ngược lại. Điều này chứng tỏ GPA giữa 2 nhóm không có sự khác biệt đáng kể.


Kiểm định t-test, vẫn lựa chọn mức ý nghĩa 5%:

- Giá trị $t = 1.452 < t\text{-critical} = 1.96$
- Giá trị $p = 0.147 > \alpha = 0.05$

→ Không đủ căn cứ để bác bỏ giả thuyết không nên biến này không có ý nghĩa thống kê, nói cách khác, việc tham gia thể thao không ảnh hưởng đáng kể đến GPA.


→ **Biến Sports không phải là một yếu tố quan trọng để thực hiện dự đoán nên có thể loại bỏ biến này để giảm nhiễu và đơn giản hóa mô hình.**

Tổng kết lại, các biến được chọn và bỏ qua như sau:



	Name	Type	Role	Values
1	StudentID	N numeric	skip	
2	Age	N numeric	skip	
3	Gender	C categorical	skip	0, 1
4	StudyTimeWeekly	N numeric	feature	
5	Absences	N numeric	feature	
6	Tutoring	C categorical	feature	0, 1
7	ParentalSupport	N numeric	skip	
8	Extracurricular	C categorical	feature	0, 1
9	Sports	C categorical	skip	0, 1
10	GPA	N numeric	target	

- **Bước 3: Tiền xử lý dữ liệu.**



Ở bước tiền xử lý dữ liệu, nhóm sử dụng widget **Preprocess** để xử lý các giá trị thiếu (missing values) và chuẩn hóa dữ liệu. Sau đó, dùng widget Outliers để phát hiện và loại bỏ các điểm dữ liệu ngoại lai.

Data Table - Orange

Info
1134 instances (no missing data)
4 features
Numeric outcome
No meta attributes.

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
☒ Select full rows


Restore Original Order

☒ Send Automatically

	GPA	StudyTimeWeekly	Absences	Tutoring	Extracurricular
1	2.929	19.8337	7	1	0
2	3.043	15.4088	0	0	0
3	2.054	10.0288	14	0	1
4	3.084	8.19122	0	0	1
5	2.748	15.6017	10	0	0
6	2.897	4.56201	1	0	0
7	3.573	18.4445	0	0	1
8	2.147	11.8514	11	0	0
9	2.397	11.1978	9	1	0
10	2.232	10.0987	14	0	1
11	2.396	10.8352	9	0	0
12	2.778	2.6216	2	0	0
13	2.978	2.71034	5	0	0
14	2.949	10.368	2	0	0
15	2.145	2.25218	8	0	0
16	2.855	18.6797	10	0	1
17	3.019	2.94908	3	1	1
18	2.625	14.294	7	0	0
19	2.809	18.7541	12	1	0
20	2.889	18.2451	9	0	0
21	4.000	18.9215	1	1	1
22	2.515	4.89431	7	0	0


1134 | 1134

- **Hình ảnh từ Data Table:** Dữ liệu từ tệp (File) nối với Bảng dữ liệu (Data Table) để hiển thị và kiểm tra nhanh trước khi xử lý.



- **Hình ảnh từ widget Preprocess:**


- Ở mục **Impute Missing Values**, chọn “*Average/ Most frequent*” để xử lý các giá trị bị thiếu bằng giá trị trung bình hoặc giá trị xuất hiện nhiều nhất.
- Ở mục **Normalize Features**, chọn “*Standardlize to $\mu = 0, \sigma^2 = 1$* ” để chuẩn hóa dữ liệu theo phương pháp Z-score Standardlization. Việc này giúp dữ liệu có phân phối chuẩn hơn, phù hợp cho nhiều thuật toán học máy và tránh sự ảnh hưởng của đơn vị đo lường, giúp các đặc trưng có quy mô tương đương.



- **Hình ảnh từ widget Outliers:**

- Chọn Contamination ở mức 10%, có nghĩa là chọn mức 10% dữ liệu sẽ bị đánh dấu là ngoại lai.
- Sau đó, nối widget Outliers với 2 bảng dữ liệu Outliers (chứa dữ liệu ngoại lai) và Inliers (chứa dữ liệu hợp lệ được giữ lại).
- Dùng widget **Save Data** để lưu bảng dữ liệu **Inliers**.

- **Bước 4: Dùng các mô hình học máy khác nhau để xử lý dữ liệu.**



Ở bước này, nhóm lựa chọn 3 mô hình học máy **Linear Regression, Gradient Boosting** và **Neural Network** để dự đoán dữ liệu và đánh giá hiệu suất.

- **Linear Regression (Hồi quy tuyến tính):** Một mô hình đơn giản dùng để dự đoán giá trị liên tục dựa trên mối quan hệ tuyến tính giữa các biến.
- **Gradient Boosting:** Một phương pháp mạnh mẽ dựa trên cây quyết định, giúp cải thiện độ chính xác bằng cách kết hợp nhiều mô hình yếu.
- **Neural Network (Mạng nơ-ron nhân tạo):** Một mô hình phức tạp, có khả năng học các mẫu dữ liệu phi tuyến tính tốt hơn.

Chúng ta kết nối 3 mô hình học máy trên cùng với file dữ liệu Inliers đã lưu ở bước 3 vào widget **Test and Score**. Đây là một widget trong Orange, dùng để đánh giá hiệu suất của mô hình học máy. Nó giúp so sánh nhiều mô hình khác nhau bằng cách sử dụng các phương pháp đánh giá phổ biến.

- **Bước 5: Đánh giá các mô hình để lựa chọn thuật toán tối ưu nhất.**

Test and Score - Orange

☒ Cross validation
 Number of folds: 5
☐ Stratified
☐ Cross validation by feature
☐ Random sampling
 Repeat train/test: 5
 Training set size: 70 %
☒ Stratified
☐ Leave one out
☐ Test on train data
☐ Test on test data

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	0.068	0.262	0.208	0.078	0.693
Neural Network	0.071	0.267	0.212	0.079	0.680
Gradient Boosting	0.072	0.269	0.214	0.080	0.675

Ảnh bên là kết quả đánh giá các mô hình từ widget Test and Score. Nhóm đã lựa chọn phương pháp Cross Validation với 5 folds.

Phân tích từng chỉ số:

MSE (Mean Squared Error – Sai số bình phương trung bình).

- Đo lường trung bình của tổng bình phương sai số giữa giá trị thực và giá trị dự đoán.
- Giá trị càng nhỏ, mô hình càng chính xác.
- **Linear Regression** có MSE thấp nhất (0.068) → Dự đoán tốt hơn hai mô hình còn lại.

RMSE (Root Mean Squared Error - Căn bậc hai sai số bình phương trung bình).

- Cũng đo lường lỗi nhưng ở dạng căn bậc hai của MSE.
- **Linear Regression** có RMSE nhỏ nhất (0.262) → Dự đoán sát thực tế hơn.

MAE (Mean Absolute Error – Trung bình sai số tuyệt đối).

- Trung bình của tổng giá trị tuyệt đối của sai số. Cho biết sai số trung bình của mô hình mà không bị ảnh hưởng bởi lỗi lớn.
- **Linear Regression** có MAE thấp nhất (0.208), tốt hơn Neural Network (0.212) và Gradient Boosting (0.214).

MAPE (Mean Absolute Percentage Error – Phần trăm trung bình sai số tuyệt đối).


- Đo lường lỗi dự đoán dưới dạng phần trăm so với giá trị thực. Giúp đánh giá mô hình dễ dàng hơn khi dữ liệu có quy mô khác nhau.
- **Linear Regression** có MAPE thấp nhất (0.078).

R² (Coefficient of Determination – Hệ số xác định).

- Giá trị từ 0 → 1, càng gần 1 thì mô hình càng tốt.
- Linear Regression có R² cao nhất (0.693), tức là giải thích được 69.3% phương sai dữ liệu.

• Bước 6: Dùng thuật toán tốt nhất để dự đoán GPA.

Từ những so sánh ở bước 5, ta đi đến kết luận rằng **Linear Regression** có hiệu suất tốt nhất so với hai mô hình còn lại vì có lỗi thấp nhất (MSE, RMSE, MAE, MAPE) và R² cao nhất → **Mô hình giải thích dữ liệu tốt nhất.**



	GPA	Linear Regression	Neural Network	Gradient Boosting	Fold	StudyTimeWeekly	Absences	Tutoring	Extracurricular
1	2.054	2.1487	2.16723	2.30042	1	-0.0780952	1.215	0	1
2	3.084	3.27156	3.3383	3.30863	1	-0.405155	-1.457	0	1
3	2.396	2.4297	2.34665	2.44539	1	0.0654245	0.261	0	0
4	2.100	1.9537	2.34558	2.22692	1	1.32313	1.787	0	0
5	2.935	2.93921	2.96801	2.94272	1	1.19583	-0.502	0	0
6	3.347	3.32029	3.39304	3.36701	1	1.05382	-0.884	1	0
7	3.262	3.27652	3.24681	3.1512	1	1.36049	-0.312	1	1
8	2.532	2.85564	2.79508	2.83936	1	0.701218	-0.121	0	1
9	2.555	2.48	2.58898	2.50504	1	-1.77962	-0.502	0	0
10	3.102	2.90225	2.81433	2.91479	1	0.412936	-0.693	0	0
11	3.498	3.26884	3.37222	3.14348	1	-1.40372	-1.266	1	1
12	2.105	2.58969	2.58828	2.61663	1	1.10211	0.261	0	0
13	3.030	2.88222	2.86159	2.81949	1	-0.803797	-1.075	0	0
14	2.123	2.33026	2.30701	2.40075	1	0.0114415	0.833	0	1
15	2.034	2.22678	2.3767	2.31773	1	1.51474	1.597	0	1
16	2.432	2.8303	2.75126	2.763	1	-0.98737	-0.121	1	1
17	2.315	2.3509	2.32106	2.35528	1	0.638901	0.642	0	0
18	2.805	2.92049	2.98347	2.98362	1	-1.09927	-1.266	0	0
19	3.719	3.48116	3.62881	3.45743	1	0.465794	-1.457	1	0
20	3.186	3.24347	3.31961	3.10925	1	1.64294	-0.502	1	0

Hình ảnh bảng kết quả dự đoán của 3 mô hình học máy Linear Regression, Neural Network và Gradient Boosting trong Orange.

CHƯƠNG 3: KẾT QUẢ CỦA NGHIÊN CỨU VÀ THẢO LUẬN.

Trong quá trình thực nghiệm, nhóm đã nghiên cứu được phương pháp dự đoán GPA của học sinh phổ thông nhờ vào các mô hình học máy trên công cụ Orange. Kết quả của nghiên cứu này đã giúp chúng ta giải đáp được 3 thắc mắc quan trọng được nêu lên ở đầu bài.

Thứ nhất, *“Các yếu tố ảnh hưởng đến GPA cuối kỳ của học sinh phổ thông”*.

Theo các dữ liệu được phân tích, ta nhận thấy rằng GPA của học sinh chịu ảnh hưởng bởi nhiều yếu tố bao gồm các yếu tố cá nhân, gia đình, trường học, bạn bè và môi trường học tập. Mặc dù mức độ tác động của từng yếu tố lên GPA có thể khác nhau, nhưng tất cả đều góp phần định hình kết quả học tập của các em. Như trong bài nghiên cứu đã nhắc đến, yếu tố “số ngày nghỉ học” của học sinh có tác động rất lớn và rõ rệt đến GPA, cho thấy rằng đến trường là một việc rất cần thiết và quan trọng đối với các em học sinh cấp 3. Dù có khả năng tự học, em vẫn cần tham gia lớp học để tiếp thu bài giảng, lắng nghe những hướng dẫn từ thầy cô nhằm nâng cao hiệu quả học tập và đạt kết quả tốt nhất.

Thứ hai, *“Thuật toán học máy nào là tối ưu và đem lại kết quả dự đoán có độ chính xác cao nhất?”*

Theo như kết quả của bài nghiên cứu, thuật toán Linear Regression sẽ mang lại kết quả tốt nhất vì nó có sai số thấp nhất và giải thích được phần lớn phương sai của các biến mục tiêu. Tuy nhiên, trong thực tế, không có mô hình học máy nào là tối ưu tuyệt đối cho mọi bài toán. Hiệu suất của thuật toán phụ thuộc vào nhiều yếu tố như đặc điểm của tập dữ liệu, số lượng mẫu, loại và số lượng đặc trưng, cũng như mục tiêu dự đoán.

Thứ ba, *“Ý nghĩa thực tiễn của nghiên cứu này là gì? Các bạn học sinh có thể cải thiện kết quả cuối kì của mình bằng cách nào dựa trên các dự đoán?”*

Nghiên cứu “Dự đoán GPA cuối kỳ của học sinh phổ thông” có ý nghĩa thực tiễn rất quan trọng trong việc cải thiện kết quả học tập. Điểm số không phải là tất cả, nhưng điểm số thấp có thể gây ra những ảnh hưởng tiêu cực đến tương lai của học sinh. GPA thấp có thể hạn chế cơ hội vào các trường đại học tốt, giảm khả năng nhận học bổng và thậm chí ảnh hưởng đến cơ hội việc làm sau này, đặc biệt là trong những ngành có yêu cầu học thuật cao. Ngoài ra, kết quả học tập kém có thể khiến học sinh mất tự tin, giảm động lực học tập và gặp khó khăn trong việc định hướng tương lai.

Trong mùa thi tốt nghiệp đang đến gần, việc dự đoán GPA có thể giúp các tân sinh viên tương lai lựa chọn đúng ngôi trường có mức điểm phù hợp với năng lực của mình. Điều này không chỉ giúp các em có định hướng rõ ràng hơn mà còn giảm bớt áp lực và lo lắng trong quá trình xét tuyển. Mặt khác, nếu nhận thấy GPA dự đoán chưa đủ để đạt được ngưỡng điểm vào ngôi trường mơ ước, học sinh sẽ có thêm thời gian để điều chỉnh chiến lược học tập, nỗ lực hơn và quyết tâm hơn trên con đường chinh phục mục tiêu của mình. Nhờ đó, việc dự đoán GPA không chỉ mang ý nghĩa đánh giá kết quả học tập mà còn là một công cụ hữu ích giúp học sinh chủ động hơn trong việc lập kế hoạch cho tương lai.

Dựa vào dự đoán của nghiên cứu “Dự đoán GPA cuối kỳ của học sinh phổ thông”, các bạn học sinh có thể cải thiện GPA bằng cách:

Hạn chế số ngày nghỉ học: Nếu không có lý do thực sự cần thiết, hãy đi học đầy đủ. Việc tham gia đầy đủ các tiết học giúp học sinh không bỏ lỡ kiến thức quan trọng, duy trì sự kết nối với bài giảng và dễ dàng tiếp thu hơn. Như câu nói: *“Học không chơi đánh rơi tuổi trẻ, chơi không học bán rẻ tương lai.”*, việc cân bằng giữa học tập và vui chơi là rất quan trọng, nhưng trước tiên, nền tảng kiến thức vững chắc phải được đặt lên hàng đầu.

Tăng cường hoạt động ngoại khóa: Học tập căng thẳng liên tục có thể gây ra sự quá tải và giảm hiệu suất. Việc tham gia các hoạt động ngoại khóa không chỉ giúp học sinh thư giãn mà còn rèn luyện các kỹ năng mềm quan trọng như quản lý thời gian, làm việc nhóm và sáng tạo ra những phương pháp học mới phù hợp với bản thân hơn. Đôi khi, một tinh thần thoải mái lại giúp quá trình học tập trở nên hiệu quả hơn.

Tìm kiếm sự hỗ trợ khi cần thiết: Nếu đã học đầy đủ trên lớp, làm bài tập chăm chỉ nhưng vẫn không đạt được GPA mong muốn, có thể bạn đang gặp khó khăn trong phương pháp học tập. Khi đó, đừng ngại tìm đến sự hỗ trợ như học thêm, học gia sư hoặc tham gia các nhóm học tập. Việc học cùng người khác có thể giúp bạn tiếp cận vấn đề theo một góc nhìn mới, hiểu sâu hơn và cải thiện kết quả học tập.

Bằng cách áp dụng những chiến lược trên, học sinh có thể từng bước nâng cao GPA của mình, hướng đến mục tiêu học tập tốt hơn và mở ra nhiều cơ hội trong tương lai.

PHẦN KẾT LUẬN

KẾT LUẬN VÀ ĐỀ XUẤT NGHIÊN CỨU CHO TƯƠNG LAI

Qua việc ứng dụng các mô hình học máy và phân tích dữ liệu, nhóm chúng em đã nhận thấy rằng điểm trung bình (GPA) của học sinh cấp 3 chịu ảnh hưởng bởi nhiều yếu tố như thời gian học hàng tuần, hoạt động ngoại khóa, số ngày nghỉ,... và có thể dự đoán được thông qua các mô hình phân tích dữ liệu. Kết quả từ nghiên cứu không chỉ giúp học sinh nhận diện các yếu tố có tác động đáng kể đến thành tích học tập một cách rõ ràng hơn mà còn tạo ra một bước tiến mới trong việc đưa ứng dụng mô hình dự đoán vào việc định hướng chọn trường đại học phù hợp với năng lực của từng học sinh, đồng thời giúp nhà trường và các tổ chức giáo dục đưa ra định hướng đúng đắn và kịp thời cho học sinh nhằm cải thiện kết quả học tập trong tương lai. Đây cũng là một tiền đề để nâng cao hiệu quả hướng nghiệp và góp phần giảm thiểu rủi ro chọn sai ngành - một trong những nguyên nhân chủ yếu ảnh hưởng đến chất lượng nguồn nhân lực sau này.

Bằng cách triển khai và thử nghiệm 3 mô hình dự đoán là Linear Regression, Gradient Boosting và Neural Network với cơ sở là các chỉ số đánh giá hiệu năng như MSE, RMSE, MAE, MAPE và R^2 , kết quả cho thấy Linear Regression là mô hình hiệu quả nhất đối với dự đoán này. Cụ thể hơn, Linear Regression đạt giá trị MSE thấp nhất (0.068) và R^2 cao nhất (0.693), chứng tỏ mô hình này có khả năng giải thích và dự đoán điểm trung bình chính xác và hiệu quả hơn so với hai mô hình còn lại. Mặc dù Neural Network và Gradient Boosting là những mô hình có thể xử lý tốt các bài toán có dữ liệu lớn và phức tạp, nhưng trong phạm vi dữ liệu của nhóm, chúng lại có độ chính xác thấp hơn so với Linear Regression. Dựa trên kết quả thu được từ dự đoán, các trường học và tổ chức giáo dục có thể cân nhắc việc đưa ứng dụng mô hình dự đoán để hỗ trợ học sinh trong việc tự đánh giá năng lực của bản thân, từ đó có thể xây dựng phương pháp học tập hiệu quả và hơn hết là sẽ cái nhìn rõ ràng hơn về việc chọn ngành nghề và môi trường đại học phù hợp với năng lực cá nhân.

Mặc dù kết quả nghiên cứu đã cho ta một cái nhìn trực quan về dự đoán nhưng nhóm nhận thấy vẫn còn nhiều hạn chế chưa được khắc phục, như độ chính xác còn phụ thuộc khá nhiều vào chất lượng dữ liệu đầu vào. Chính vì vậy, nhóm đề xuất hướng nghiên cứu tốt hơn trong tương lai nhằm cải thiện chất lượng dự đoán bằng những phương pháp như mở rộng quy mô dữ liệu, ứng dụng thêm các mô hình học sâu (Deep Learning), thu thập dữ liệu từ nhiều nguồn khác nhau,... Đồng thời, việc tích hợp mô hình dự đoán này vào các nền tảng quản lý học tập trực tuyến cũng sẽ là một phương pháp đáng cân nhắc, giúp học sinh và giáo viên có

thể tiếp cận với các dự đoán và phân tích về kết quả học tập một cách nhanh chóng và thuận tiện nhất.

Nhìn chung, nghiên cứu mô hình dự đoán này là bước khởi đầu quan trọng trong việc ứng dụng trí tuệ nhân tạo và các mô hình học máy vào lĩnh vực giáo dục, với mục đích xây dựng hệ thống giáo dục hiệu quả và đa dạng hơn, phù hợp với năng lực và khả năng của từng học sinh. Nhóm hi vọng rằng nghiên cứu này đã cho các bạn học sinh một cái nhìn khái quát về việc lựa chọn ngành nghề và môi trường học tập, từ đó xây dựng được kế hoạch học tập và phát triển bản thân trong tương lai.

TÀI LIỆU THAM KHẢO

- [1]. Trang, V. (2025, March 1). *Giáo dục*. Retrieved from Lao động: <https://laodong.vn/giao-duc/phuong-an-xet-hoc-ba-vao-cac-truong-dai-hoc-nam-2025-1471717.ldo>
- [2]. Thu, L. (2025, March 3). *Sống*. Retrieved from CAFEF: <https://cafef.vn/thac-si-stanford-canh-bao-loi-sai-khien-ung-tuyen-truot-dai-hoc-top-1-the-gioi-188250303135257721.chn>
- [3]. Cristóbal Romero, M.-I. L.-M. (2013, January 17). Retrieved from Science Direct: <https://www.sciencedirect.com/science/article/abs/pii/S0360131513001607>
- [4]. Ganaie, A. I. (2020). A Comparative Study of Machine Learning Algorithms for Predicting Student Performance. *International Journal of Advanced Computer Science and Applications*, 505-513.
- [5]. Lưu Hoài Sang, N. T. (2020). *Dự báo kết quả học tập bằng kỹ thuật học sâu với mạng nơ-ron đa tầng*. Retrieved from Tạp chí Khoa học Đại học Cần Thơ: <https://ctujsvn.ctu.edu.vn/index.php/ctujsvn/article/view/3625>
- [6]. Kharoua, R. E. (2024, June). *Students Performance Dataset* . Retrieved from Kaggle: <https://www.kaggle.com/datasets/rabieelkharoua/students-performance-dataset>

KIỂM TRA ĐẠO VĂN

Match Overview

×

11%

<

>

1

Hanoi National Universi...

Publication

6%

>

2

ussh2021conference.w...

Internet Source

2%

>

3

Võ Hoàng Khang, Huyn...

Publication

1%

>

4

sbf.edu.vn

Internet Source

1%

>

5

luutruvn.com

Internet Source

1%

>